

Ⅱ. 일반 회귀분석 (Regression)

③ Linear Regression Ⅲ


※ 참고 - 편의(Bias) vs 분산 (Variance) Trade-off

분산이 적은 모형이 좋은가, 편의가 적은 모형이 좋은가?


$$MSE = Variance + (Bias)^2$$

평균제곱오차(Mean Square Error, MSE)는
분산(Variance)와 편의(Bias)로 분해할 수 있으며,
평균제곱오차가 동일할 경우, 분산과 편의 간에는
트레이드 오프(Trade-off) 관계가 있음

따라서, 분산과 편의를 모두 줄이는 가장 이상적인
경우(Ideal case)가 아니라면, 분산과 편의의 적절한
수준에서 최적의 모형을 찾는 것이 가장 바람직함



※ 참고 - 편의(Bias) vs 분산 (Variance) Trade-off




잔차제곱합 (RSS :Residual sum of squares)

MSE(Mean Square Error)가 낮으면 무조건 좋은 모형일까?

- RSS를 이용해 MSE를 계산하고, 이를 기준으로 MSE가 가장 낮은 모형을 택함으로써 변수선택에 활용하는 것이 전통적인 시각
- 하지만, 과적합(Overfitting)일 경우 RSS는 0에 근접하게 되어 올바른 변수선택을 할 수 없음

$$RSS = \sum_{i=1}^n (y_i - \hat{y})^2$$

- 변수를 무한히 넣으면 모형의 설명력은 무한히 증가함



전통적인 변수선택 방법

1. Mallows's C_p 통계량('70년대)

$$C_p = \frac{RSS_d}{\sigma^2} + 2d - n$$

2. AIC(Akaike Information Criterion)

$$AIC = \frac{RSS_d}{\sigma^2} + 2d$$

3. BIC(Bayesian Information Criterion)

$$BIC = \frac{RSS_d}{\sigma^2} + 2d * \log(n)$$

L1, L2 벌점화 최소제곱법

$$\hat{\beta}^{ols} = \arg \min ||Y - X\beta||^2$$



$$\hat{\beta}^{ridge} = \arg \min ||Y - X\beta||^2 - \lambda ||\beta||^2 = (X'X + \lambda I_p)^{-1} X'Y$$

bias

$$\hat{\beta}^{lasso} = \arg \min ||Y - X\beta||^2 - \lambda \sum_{j=1}^p |\beta_j|$$

벌점모수(Penalty parameter)
람다(Lambda)를 결정해야 함

Shrinkage Estimator



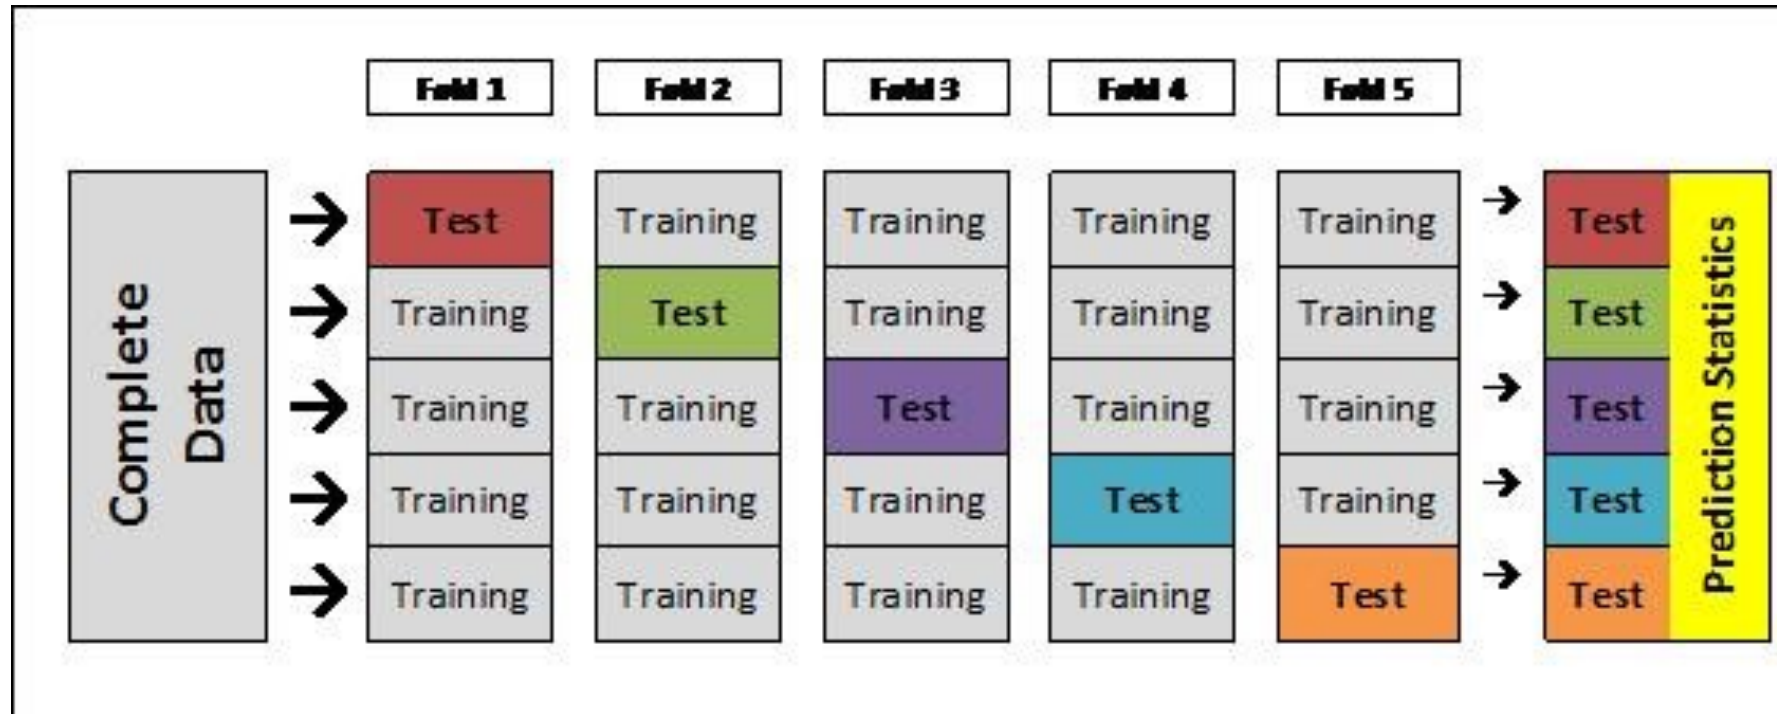
LASSO(least Absolute Shrinkage and Selection Operator)

- 1) 샘플의 개수보다 변수의 개수가 많은 ($n < p$) 고차원 데이터 분석에 적합함
- 2) Sparse solution을 제공해줌(유의미하지 않은 회귀계수의 값을 exactly zero로 만들어 줌)
- 3) 2)에 의해 변수선택의 기능이 있음(Ridge와 다른 점임)
- 4) 추정된 회귀계수의 값이 OLS의 회귀계수에 비해 0에 가까운 값을 지님(Shrinkage estimator)
- 5) Logistic Model에서도 적용 가능함
- 6) 모형에 대한 특정 가정이 존재하지 않음(가령, 오차의 정규성 등)


K-fold cross-validation

- 1) 데이터를 random하게 k개의 같은 크기로 쪼갬
- 2) K-1-fold의 데이터를 트레이닝 데이터로 이용하여 모델을 학습시킴
- 3) 나머지 데이터(hold-out set)의 Y값을 예측(Prediction)
- 4) 1~3번 과정을 K번 반복해 모든 Y값에 대한 예측값(Predicted value)을 찾아냄
- 5) 1~4번까지 과정을 각각의 후보모델마다 실행함
- 6) 1-5까지 과정을 반복함
- 7) MSE를 계산하고, 이를 최소화하는 모델 혹은 벌점모수를 선택함

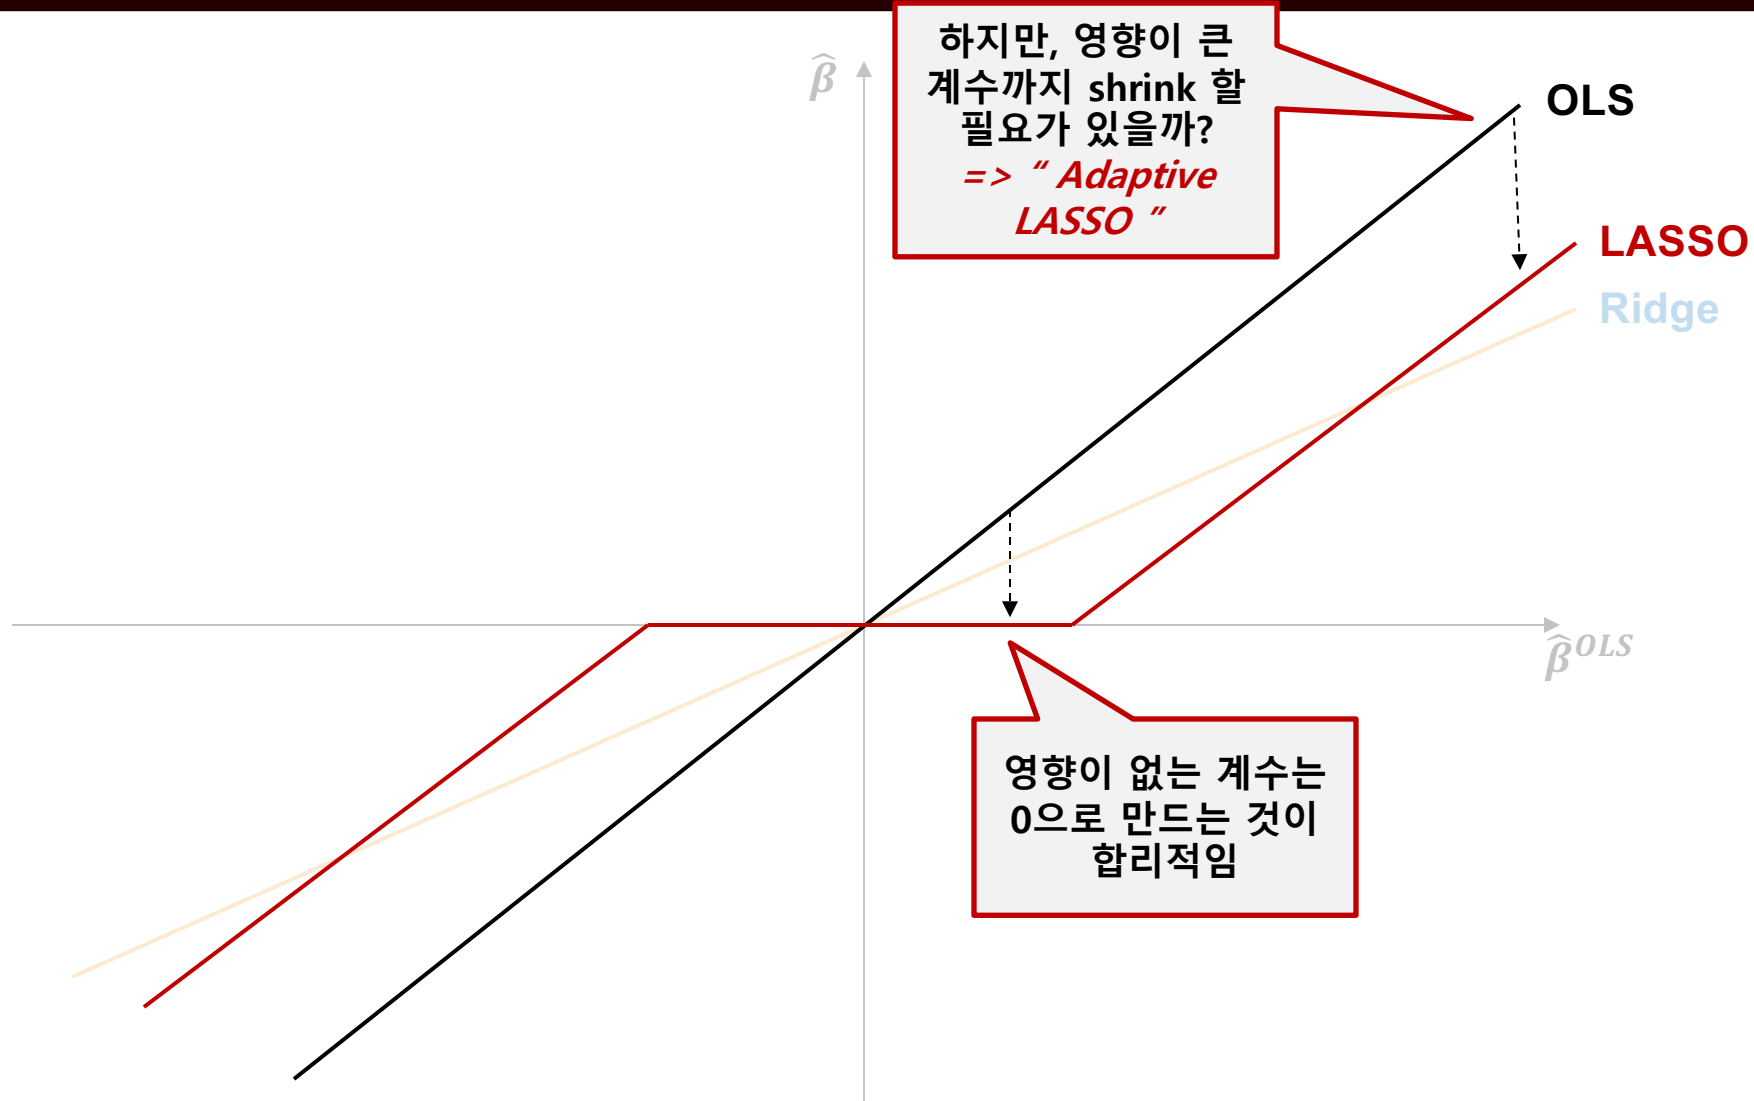
예) 5-fold cross-validation



회귀계수 값들의 비교



회귀계수 값들의 비교



LASSO의 한계와 극복방안

Case#1 -> Adaptive LASSO

- ✓ OLS는 Consistent estimator인데 반해, Lasso는 아님
- ✓ 즉, 샘플 수가 무한히 늘어나도 유의미한 변수를 선택하지 못하거나 무의미한 변수를 선택할 수 있음

-> 유의미한 변수의 경우, shrinkage 정도를 줄여줘야 함!

- ✓ Adaptive LASSO

$$\hat{\beta}^{alasso} = \arg \min ||Y - X\beta||^2 - \lambda \sum_{j=1}^p \hat{w}_j |\beta_j| \quad , \quad \hat{w}_j = \frac{1}{\hat{\beta}_{ols}}$$

OLS에서 계수값이 클수록,
Weight는 작아져 penalty를
적게 받음

Case#2 -> Elastic Net

- ✓ 선택할 수 있는 최대 변수의 수 = Sample의 수
- ✓ 변수가 그룹화 되어 있을 경우, LASSO는 무시함
- ✓ 변수 간 Correlation 높은 경우, LASSO의 Solution path는 매우 불안정함